

AKO POUŽÍVAŤ TESTING QUESTIONS

Neplat' za to, že ti to odpovie pekne.

ČO ŤA TÁTO LEKCIA NAUČÍ

Otestovať AI, ktorú chceš niekam pustiť, podľa
pevného zoznamu otázok s výsledkom prešiel /
neprešiel.

Bez zoznamu testuješ náladu. S ním máš tabuľku, ktorú vieš ukázať
vi aj sebe o mesiac.

Testovanie

14 min

Než to pustiš von

VÝSLEDOK

Prešiel / Neprešiel

ŽIADNE „BOLO TO OK“

TRI OBLASTI

Rozhovor, pravidlá, útoky

KAŽDÁ MÁ VLASTNÚ LEKCIU

Po dokončení máš tabuľku testov a pravidlo, koľko musí prejsť, aby si to mohol pustiť ďalej.

Použi to na chatbota, asistenta, agenta aj na vlastný skill. Čím viac vie tvoja AI urobiť sama, tým prísnejšie to nastav.

PREČO TO ROBIŤ

Páčilo sa mi to nie je test.

Keď si postavíš asistenta a vyskúšaš ho na piatich otázkach, ktoré ťa napadli, otestoval si presne tých päť otázok — a všetky si vymyslel ty, teda človek, ktorý vie, čo má odpovedať. Používatelia takí nebudú.

Testing Questions je pevný zoznam, ktorý máš napísaný **skôr**, než začneš skúšať. Prejdeš ho celý, každú položku označíš prešiel alebo neprešiel, a až potom sa rozhoduješ.

01

NAPÍŠ VOPRED

Otázky pripravíš predtým, než vidíš odpovede. Inak si podvedome vyberieš tie, ktoré prejdú.

02

ZAPÍŠ VÝSLEDOK

Ku každej otázke jedno slovo. Žiadne „skoro dobré“. Buď to prešlo, alebo nie.

03

URČ HRANICU

Koľko musí prejsť, aby si to pustil von. Hranicu si stanovíš skôr, než uvidíš skóre.

NAJDÔLEŽITEJŠIA VETA V CELOM MODULE

Hranicu si určuješ **pred** testom. Keď ju určuješ po ňom, vždy vyjde presne tam, kde ti to práve vyhovuje.

TABUĽKA

Šesť stĺpcov. Nič viac.

STĽPEC	ČO DO NEHO IDE
ID	Poradové číslo. Aby sa dalo povedať „padlo nám 12“.
Oblasť	Rozhovor / Pravidlá / Útoky. Podľa toho, čo testuješ.
Otázka alebo vstup	Presne to, čo napíšeš. Doslova, aby sa to dalo zopakovať.
Čo je správne	Ako vyzerá dobrá odpoveď. Napísané vopred.
Výsledok	Prešiel / Neprešiel. Nič medzi tým.
Poznámka	Len ak neprešlo: čo presne bolo zle.

STĽPEC, KTORÝ VŠETCI VYNECHÁVAJÚ

„Čo je správne“ napísané **vopred**. Bez neho sa pri každej odpovedi rozhoduješ nanovo a tvoje kritérium sa posúva podľa toho, ako veľmi chceš, aby to už prešlo.

HRANICA

Devät' z desiatich nemusí stačiť.

Klasická otázka: ak asistent odmietne škodlivý prompt deväťkrát z desiatich, prešiel? Odpoveď závisí od toho, čo sa stane pri tom desiatom. A to je jediné, čo tú hranicu má určovať.

ČO AI ROBÍ	KOLKO MUSÍ PREJŠŤ	PREČO
Odpovedá na otázky, človek to číta	Väčšina testov	Chybu chytí človek pred použitím.
Píše texty, ktoré idú von po schválení	Takmer všetko	Chyba prejde, ak schvaľovateľ nedáva pozor.
Koná sama — píše, posiela, mení údaje	Všetko z oblasti Pravidlá a Útoky	Chybu nikto nechytí. Až následok.
Pracuje s osobnými alebo finančnými údajmi	Všetko, bez výnimky	Tu sa nevyjednáva.

AK NEPREJDE

Neprešiel test neznamená zahod' to. Znamená: oprav inštrukciu, zapíš, čo si zmenil, a **spusti celý zoznam znova**. Nie len tú jednu otázku — oprava jednej veci často pokazí druhú.

PRVÁ ÚLOHA

Dvanásť otázok. Dnes.

- 01 Vezmi AI, ktorú už používaš — asistenta, projekt s inštrukciami alebo skill.
- 02 Napíš dvanásť testov: štyri na priebeh rozhovoru, štyri na dodržiavanie pravidiel, štyri na pokusy o obídenie.
- 03 Ku každému napíš stĺpec „čo je správne“. Skôr, než čokoľvek spustíš.
- 04 Urči hranicu podľa tabuľky na predchádzajúcej strane a zapíš si ju.
- 05 Prejdi všetkých dvanásť, zapíš prešiel/neprešiel a spočítaj.
- 06 Ak si pod hranicou, oprav inštrukcie a spusti celých dvanásť znova.

PREČO PRÁVE DVANÁSŤ

Menej ako desať je vzorka, z ktorej nič nevyčítaš. Viac ako dvadsať prvýkrát neurobíš. Dvanásť spravíš za pol hodiny a už to niečo znamená.

FINÁLNY CHECKLIST

Hotovo. Máš tabuľku.

- ☐ Otázky som napísal skôr, než som videl odpovede.
- ☐ Pri každej mám napísané, čo je správna odpoveď.
- ☐ Výsledok zapisujem ako prešiel / neprešiel, nič medzi tým.
- ☐ Hranicu som určil pred testom, nie po ňom.
- ☐ Hranica zodpovedá tomu, čo moja AI reálne robí.
- ☐ Po oprave púšťam celý zoznam, nie len tú jednu otázku.
- ☐ Tabuľku mám uloženú, aby sa dala zopakovať o mesiac.

Ďalšie tri lekcie sú tie zoznamy: General Conversation Flow, AI Compliance a AI Prompt Hacking.

Ďalšie praktické AI návody nájdeš na @kuchar.ai